

НОРНИКЕЛЬ · AI SCIENCE HACK · ТРЕК «НАУЧНЫЙ КЛУБОК» · 2026

Научный клубок

Единая R&D-карта знаний горно-металлургической отрасли. Граф знаний + гибридный поиск отвечают на сложные технические вопросы экспертов — с цитатами, достоверностью и датой актуализации. Не «RAG поверх PDF».

- Граф 2100+ узлов, 12 типов
- LLM-агностично: YandexGPT / MetalGPT-1
- Ретривал ~0,45 с · без GPU

01

Знания R&D рассеяны

В точке ноль проблема не в отсутствии моделей, а в отсутствии **структуры**. Институциональная память отрасли теряется между отчётами, статьями и архивами лабораторий.

Ответ на один технический вопрос эксперта = ручной сбор из десятков источников на несколько дней. Мы сводим это к секундам — с провенансом.

→ **Дублирование:** команды повторяют литобзоры, не видя, что работа уже сделана

→ **Нет междисциплинарных связей:** «режим обработки → выход металла» не проследить

→ **Многопараметрический поиск невозможен:** материал + процесс + условия + гео + годы

→ **Противоречия:** выводы разных источников без единой верифицированной базы

→ **Численные фильтры теряются:** «сульфаты ≤ 300 мг/л», «сухой остаток ≤ 1000 мг/дм³»

Пять более — дословно из вашего ТЗ. «Научный клубок» закрывает каждую одним графом знаний и одним окном поиска.

02

Решение — граф знаний + гибридный поиск

Мы связываем публикации, эксперименты, материалы, процессы, оборудование и экспертов в единый граф. Вектор находит смысл, граф даёт структуру и доказательную базу. Каждый ответ — с источником, уровнем достоверности и датой.

ГИБРИДНЫЙ ПОИСК

Граф + вектор, не «RAG поверх PDF»

Вектор → seed-узлы → обход графа 1–4 хопа → реранк → генерация. Структура важнее плоского чанка.

ПРОВЕНАНС

Цитата, достоверность, актуальность

Каждый факт несёт evidence-цитату, уровень верификации и дату. Версионирование фактов.

ФИЛЬТРЫ ИЗ ВОПРОСА

Числа · РФ/мир · годы

«≤300 мг/л», «за последние 5 лет», «в мировой практике» распознаются прямо из текста запроса.

АНАЛИТИКА

Пробелы · сравнение · эксперты

Поиск дыр в данных (вкл. гео-перекос), сравнение технологий, эксперты по теме, литобзор.

ПРОДАКШН

RBAC + аудит · экспорт · дашборд

5 ролей с видимостью данных, аудит, экспорт PDF/MD/JSON-LD, ручная правка графа экспертом.

РАЗВЁРТЫВАНИЕ

Без GPU · одна команда

docker compose up — Neo4j + Qdrant + API + UI с готовым seed-графом. Или портативно без Docker.

03

Онтология: 12 типов сущностей

Домен-специфичная схема горно-металлургического R&D. Не generic-NER, а типизированный граф: LLM извлекает триплеты строго по онтологии в JSON, каждый — с evidence-цитатой из источника.

2111

УЗЛОВ ГРАФА

1436


РЁБЕР-СВЯЗЕЙ

12

ТИПОВ СУЩНОСТЕЙ

15


ТИПОВ СВЯЗЕЙ



04

Архитектура · LLM-агностичность, без GPU

Один пайплайн, сменные бэкенды. Сегодня — YandexGPT в облаке; в проде Норникеля — тот же код с **MetalGPT-1 on-prem**, клиент уже написан. Эмбединги локальные (ONNX) — без облачной квоты и без GPU.



СМЕННЫЕ БЭКЕНДЫ · ОДНА СТРОКА В .env

LLM	LLM_BACKEND : yandex → metalgpt (on-prem) → mock
Эмбеддер	EMBEDDER_BACKEND : fastembed (ONNX, локально) → yandex → bge
Хранилища	Neo4j + Qdrant · embedded или server (docker)

Прод-трек готов. Клиент MetalGPT-1 (vLLM, OpenAI-совместимый) уже реализован — переключение бэкенда не требует изменений пайплайна. Данные не покидают периметр.

Устойчивость: сбой эмбеддера → graph-only ответ; сбой LLM → структурный флаг `llm_ok=false` + подграф с источниками. Батч-ингест: ретраи + чекпоинт.

05

Гибридный поиск в деталях

Пять ступеней превращают вопрос на естественном языке в ответ с доказательной базой. Структурные фильтры (числа/гео/годы) применяются **внутри обхода графа**, до генерации.

1 · Вектор Семантический recall топ-k чанков (fastembed)

2 · Seed Точки входа в граф: fulltext Neo4j + морфология

3 · Обход 1–4 хопа + фильтры чисел / гео / годов

4 · Реранк bi-encoder выносит релевантные рёбра вперёд

5 · Генерация LLM отвечает строго по подграфу + цитаты

РАСПАД ВРЕМЕНИ РЕТРИВАЛА · МЕДИАНА 447 МС



Бюджет ТЗ: 3000–5000 мс

Запас $\times 2$ – $\times 11$ · min 129 / max 1365 мс

Пример многопараметрического вопроса: «методы обессоливания, если сульфаты/хлориды 200–300 мг/л, сухой остаток ≤ 1000 мг/дм³» — числовые диапазоны распознаны и применены к подграфу.

Гео-откат: если «мировая практика» не находит зарубежных источников — фильтр честно снимается с оговоркой, а не выдаёт «нет данных».

06

Результаты в цифрах

Всё измерено на реальном стенде (YandexGPT + fastembed + Neo4j), а не оценено «на глаз». Held-out gold-набор не пересекается с few-shot примерами промпта.

2111

УЗЛОВ · 1436 РЕБЕР · 12 ТИПОВ

447_{мс}

МЕДИАНА РЕТРИВАЛА · БЮДЖЕТ 3-5 С

0,66

F1 ИЗВЛЕЧЕНИЯ СУЩНОСТЕЙ

68

ЮНИТ-ТЕСТОВ ЗЕЛЁНЫХ

ТОЧНОСТЬ ИЗВЛЕЧЕНИЯ ТРИПЛЕТОВ · HELD-OUT GOLD (RU)



Бэкенд YandexGPT, few-shot. Атрибуты (числа/единицы) — критичны для ТЗ: бэкфилл значений из цитат поднял F1 на ~15 п.п.

ЧЕСТНЫЕ ОГОВОРКИ

→ Gold-набор 10 примеров — индикативно; расширение до 15-20 в бэклоге

→ Кросс-язычное сопоставление меток — известный пробел (electrowinning ↔ электроэкстракция)

→ Генерация облачная 4-17 с — на on-prem MetalGPT-1кратно быстрее; ретривал <1,4 с

Мягкая деградация проверена: сбой эмбеддера → graph-only; сбой LLM → подграф + источники. Ни одна ошибка не роняет ответ целиком.

Покрытие ТЗ — все блоки закрыты

От импорта документов и онтологии до RBAC, аудита и экспорта отчётов.

Каждый пункт — рабочий код с тестами, а не слайд-обещание.

ИЗВЛЕЧЕНИЕ ЗНАНИЙ

Онтология 12 типов · триплеты с провенансом

Парсинг PDF/DOCX/PPTX, нормализация единиц (мг/л, °C, г/т), канонизация синонимов RU/EN.

МНОГОПАРАМЕТРИЧЕСКИЙ ПОИСК

Материал + процесс + условия + гео + годы

Числовые диапазоны, РФ↔мир, временные фильтры — распознаются из вопроса и применяются к графу.

ВЕРИФИКАЦИЯ

Источник · достоверность · дата

Уровни confirmed/preliminary/disputed, версионирование фактов, поиск противоречий.

АНАЛИТИКА

Пробелы · литобзор · сравнение · эксперты

Дыры в данных вкл. гео-перекос, структурный литобзор, сравнение технологий, эксперты по теме.

УПРАВЛЕНИЕ

RBAC 5 ролей · аудит · правка графа

Видимость внутренних данных по роли, журнал аудита, ручная корректировка связей экспертом.

ИНТЕГРАЦИЯ

Экспорт PDF/MD/JSON-LD · уведомления · дашборд

Отчёты в техзадания, подписки на темы, дашборд покрытия знаний и активности лабораторий.

Нефункциональные требования тоже выполнены: ретривал в бюджете 3–5 с (запас ×2–×11), развёртывание без GPU (docker compose или портативно), 68 тестов, RU/EN.

08

Прод-трек и развитие

«Научный клубок» готов к пилоту в НИИ уже сейчас, а архитектура рассчитана на промышленный масштаб корпуса Норникеля.

ДОРОЖНАЯ КАРТА

Сейчас Пилот: seed-граф 2100+ узлов, все функции ТЗ, RBAC + аудит

Шаг 1 On-prem `MetalGPT-1` — тот же код, данные в периметре

Шаг 2 Полный корпус: отчёты, патенты, лабораторные журналы

Шаг 3 Каталог экспериментов, справочники, связи с сотрудниками

ПОЧЕМУ ЭТО РАБОТАЕТ В ПРОДЕ

→ **LLM-агностичность:** смена бэкенда — строка в конфиге, не рефакторинг

→ **Периметр безопасности:** on-prem модель + локальные эмбединги, данные не уходят в облако

→ **Провенанс by design:** каждый факт аудлируем до источника и даты

→ **Мягкая деградация:** сервис отвечает даже при сбое компонента

Готово к развёртыванию: `docker compose up` — и жюри видит рабочее демо с данными за минуту.

Спасибо — готовы к вопросам.